

Classificação: Binária vs. Multiclasse

- ▶ **Classificação Binária:** O objetivo é classificar a entrada em apenas duas classes (ex: gato vs. não-gato, spam vs. não-spam).
 - ▶ A camada de saída geralmente possui 1 neurônio com função de ativação sigmoide, produzindo uma probabilidade entre 0 e 1.
 - ▶ A função de perda comum é a Entropia Cruzada Binária (Binary Cross-Entropy).
- ▶ **Classificação Multiclasse:** O objetivo é classificar a entrada em mais de duas classes (ex: diferentes raças de cães, tipos de nuvens).
 - ▶ A camada de saída geralmente possui um neurônio para cada classe, com função de ativação softmax, produzindo uma distribuição de probabilidade sobre as classes.
 - ▶ A função de perda comum é a Entropia Cruzada Categórica (Categorical Cross-Entropy).

Detecção de Objetos (Boxes)

- ▶ O objetivo é identificar a presença de múltiplos objetos em uma imagem e delimitar sua localização usando caixas delimitadoras (bounding boxes).
- ▶ Além da classificação de cada objeto dentro da caixa, o modelo precisa prever as coordenadas da caixa (ex: x_{\min} , y_{\min} , x_{\max} , y_{\max}).
- ▶ Arquiteturas comuns incluem YOLO (You Only Look Once), Faster R-CNN, e SSD (Single Shot MultiBox Detector).
- ▶ A saída do modelo inclui:
 - ▶ Classes dos objetos detectados.
 - ▶ Coordenadas das caixas delimitadoras para cada objeto.
 - ▶ Scores de confiança para cada detecção.

Segmentação Semântica

- ▶ O objetivo é atribuir um rótulo de classe a cada pixel da imagem.
- ▶ Diferentemente da detecção de objetos, a segmentação semântica não distingue instâncias separadas do mesmo objeto (todos os gatos seriam rotulados como "gato").
- ▶ Arquiteturas comuns incluem FCN (Fully Convolutional Network), U-Net, e DeepLab.
- ▶ A saída do modelo é um mapa de segmentação, onde cada pixel possui um rótulo de classe.

Modelos Pré-Treinados

- ▶ Modelos pré-treinados são redes neurais que foram treinadas em grandes datasets (geralmente ImageNet, com milhões de imagens e milhares de classes).
- ▶ Esses modelos aprenderam características genéricas que são úteis para diversas tarefas de visão computacional (ex: detecção de bordas, texturas, formas).
- ▶ **Vantagens de usar modelos pré-treinados:**
 - ▶ Reduz a necessidade de grandes datasets de treinamento para novas tarefas.
 - ▶ Acelera o processo de treinamento (convergência mais rápida).
 - ▶ Pode levar a melhor generalização e desempenho, especialmente com dados limitados.
- ▶ **Técnicas comuns de uso:**
 - ▶ **Extração de Características (Feature Extraction):** Usar as camadas convolucionais do modelo pré-treinado para extrair características da nova tarefa e treinar apenas um novo classificador (camadas totalmente conectadas) sobre essas características.
 - ▶ **Fine-tuning:** Descongelar algumas ou todas as camadas do modelo pré-treinado e continuar o treinamento no novo